

Simulador Inteligente de Portfólios: Uma Abordagem com LLM e Simulação de Monte Carlo para Apoio à Decisão em Investimentos

Alexandre Pintor da Silva,
Rafael Jordão Clemente,
Luiz Cláudio Vieira Filho and
Theo Cohen Farhat

Universidade Federal do Rio de Janeiro

Abstract. Este trabalho apresenta o desenvolvimento de um simulador inteligente de portfólios de investimento, capaz de interpretar descrições em linguagem natural do perfil do usuário e recomendar carteiras personalizadas com base em métricas avançadas de risco e retorno. A solução integra um Large Language Model (LLM) para processamento das preferências do investidor e utiliza simulação de Monte Carlo, além de métricas como Value at Risk, volatilidade, índice de Sharpe e drawdown, para avaliar o desempenho dos portfólios sugeridos. Os resultados são apresentados por meio de visualizações interativas, incluindo gráficos de retorno simulado, matriz de correlação e relação risco-retorno, facilitando a compreensão e a tomada de decisão. A aplicação busca democratizar o acesso à informação financeira, promovendo autonomia e segurança para investidores de diferentes níveis de experiência.

Keywords: Investimentos · Recomendação de Portfólio · Simulação de Monte Carlo · Large Language Model · Visualização de Dados · Risco Financeiro

1 Introdução

O cenário econômico brasileiro tem experimentado um aumento significativo do interesse da população em investir no mercado financeiro. Entretanto, a tomada de decisão relacionada a investimentos ainda representa um grande desafio para a maioria dos indivíduos. O problema central reside na dificuldade de alinhar escolhas financeiras às particularidades do perfil de cada investidor, dada a multiplicidade de produtos disponíveis, cada um com diferentes níveis de risco, liquidez e retorno esperado. A identificação e recomendação de carteiras de investimento adequadas às necessidades individuais demanda não apenas conhecimento técnico, mas também análise detalhada de variáveis de risco, objetivos pessoais e tolerância a perdas.

Esse contexto é agravado por alguns fatores recorrentes: i) muitas pessoas têm interesse em investir, mas não dispõem de tempo suficiente para estudar o funcionamento dos ativos e do mercado; ii) grande parte dos potenciais investidores relata falta de conhecimento sobre finanças e investimentos, sentindo-se inseguros ao tomar decisões; iii) o medo de perder dinheiro e a dificuldade em compreender conceitos de risco limitam o acesso de novos participantes ao universo dos investimentos. Em síntese, a democratização do acesso a produtos financeiros ainda enfrenta barreiras relacionadas ao conhecimento, tempo disponível e segurança na tomada de decisão.

O presente trabalho tem como objetivo desenvolver um simulador inteligente capaz de receber, em linguagem natural, uma descrição do perfil de investimento do usuário e, a partir disso, indicar um caminho de investimentos apropriado. O sistema recomenda uma carteira personalizada, apresenta métricas de risco associadas e oferece ao usuário recursos gráficos para facilitar a visualização e a compreensão dos resultados. Dessa forma, busca-se contribuir para a inclusão financeira, oferecendo uma solução prática e acessível para auxiliar tanto investidores iniciantes quanto experientes no processo de alocação de recursos.

2 Métodos e Ferramentas Utilizados

2.1 Large Language Model (LLM)

Os Large Language Models (LLMs) constituem a base da interface inteligente da aplicação desenvolvida. LLMs são modelos avançados de inteligência artificial baseados em redes neurais profundas, em especial arquiteturas do tipo transformers, e treinados com grandes volumes de dados textuais, como livros, artigos, sites e até código-fonte. Sua capacidade de compreender, interpretar e gerar linguagem natural permite que a comunicação entre usuário e sistema seja mais intuitiva, aproximando-se do diálogo humano. A utilização de um LLM possibilita que o perfil do investidor seja descrito em linguagem natural, com o modelo identificando, extraindo e categorizando informações relevantes para traçar recomendações personalizadas. Além disso, os LLMs conseguem adaptar as respostas e gerar conteúdo explicativo, facilitando a compreensão do usuário sobre os riscos, retornos e estratégias sugeridas.

2.2 Métricas de Risco e Desempenho

Para fornecer recomendações fundamentadas, o simulador calcula e apresenta ao usuário um conjunto de métricas amplamente reconhecidas no mercado financeiro. As principais métricas empregadas são:

- **Value at Risk (VaR):** O Value at Risk é uma métrica essencial para quantificar o risco de mercado de um ativo ou carteira. O VaR indica a perda

máxima esperada em um dado período, com um nível de confiança predefinido. É utilizado para dimensionar a exposição ao risco e embasar decisões de proteção ou diversificação de portfólio. O VaR pode ser calculado por três métodos: paramétrico (assumindo distribuição normal dos retornos), histórico (a partir dos dados passados) e simulação de Monte Carlo (gerando cenários possíveis por modelos estatísticos).

- **Stress:** A análise de stress consiste em submeter a carteira a cenários extremos de mercado para avaliar sua resiliência. Isso permite identificar pontos de fragilidade e antecipar o comportamento dos investimentos em situações adversas, auxiliando o investidor no planejamento de estratégias de mitigação de risco.
- **Correlação:** A correlação entre ativos indica o grau de associação entre os retornos deles. Uma carteira bem diversificada procura incluir ativos com baixas ou negativas correlações, reduzindo o risco agregado. A análise de correlação é fundamental para construção e recomendação de carteiras eficientes.
- **Índice de Sharpe:** O Índice de Sharpe avalia o desempenho de um investimento em relação ao risco assumido, mensurando o retorno excedente (acima do livre de risco) por unidade de volatilidade. Um Sharpe elevado indica que o investimento oferece uma boa compensação para o risco; valores abaixo de 1 apontam relação risco-retorno desfavorável.
- **Volatilidade:** A volatilidade reflete a intensidade das oscilações nos retornos de um ativo. Ativos ou portfólios com alta volatilidade apresentam maior incerteza e, conseqüentemente, maior risco. Essa métrica é fundamental para avaliação da estabilidade dos investimentos sugeridos.
- **Drawdown:** O drawdown representa a queda máxima observada do valor de um investimento em relação ao seu topo anterior, até que se recupere ou atinja novo pico. É uma medida prática do risco de perda suportado pelo investidor, permitindo a avaliação da robustez e tolerância à queda das estratégias propostas.
- **Constant Expected Return (CER):** O conceito de Constant Expected Return parte da premissa de que o retorno médio esperado de um ativo ou carteira permanece estável ao longo do tempo. Essa hipótese simplifica análises preditivas, é utilizada em simulações de cenários e fundamenta modelos clássicos como o CAPM e a teoria moderna de portfólio.

2.3 Visualização de Dados e Resultados

A aplicação proporciona ao usuário uma série de recursos gráficos interativos que facilitam a análise e a compreensão das recomendações apresentadas. Dentre as principais visualizações implementadas, destacam-se:

- **Gráfico de Retorno Simulado vs. Retorno Realizado:** Este gráfico permite comparar o desempenho projetado da carteira, com base em simulações, em relação ao histórico real dos ativos. Tal comparação auxilia o investidor a avaliar a aderência das previsões e a robustez das estratégias sugeridas, fornecendo maior segurança na tomada de decisão.

- **Matriz de Correlação:** A matriz de correlação é representada por um mapa de calor que ilustra o grau de associação entre os ativos da carteira. Essa visualização contribui para identificar relações de dependência ou independência entre os componentes do portfólio, orientando a construção de carteiras mais diversificadas e eficientes em termos de risco.
- **Gráfico Volatilidade vs. Retorno:** Por fim, este gráfico exibe a relação entre a volatilidade e o retorno esperado de cada ativo ou carteira simulada. Ao posicionar os investimentos nesse espaço, o investidor pode identificar oportunidades com melhor relação risco-retorno e compreender o perfil de cada estratégia, facilitando a escolha alinhada ao seu perfil de tolerância ao risco.

2.4 Bibliotecas Utilizadas

A implementação da aplicação foi realizada em Python, fazendo uso de um ecossistema de bibliotecas modernas e consolidadas, que possibilitam desde o processamento eficiente dos dados até a construção de interfaces interativas para o usuário. As principais bibliotecas utilizadas são:

- **Streamlit:** Trata-se de uma biblioteca de desenvolvimento front-end voltada para aplicações de Data Science e Machine Learning. Permite criar interfaces web interativas de maneira rápida e intuitiva, facilitando a visualização de gráficos, tabelas e resultados analíticos diretamente no navegador, sem necessidade de conhecimentos avançados em desenvolvimento web.
- **Langchain:** Utilizada para integrar o Large Language Model (LLM) à aplicação, a Langchain facilita o gerenciamento dos fluxos de interação entre o usuário e o modelo de linguagem, permitindo a extração, categorização e personalização das informações recebidas em linguagem natural.
- **Yahoo Finance:** Biblioteca empregada para obtenção de dados históricos de preços dos ativos do S&P 500. O acesso facilitado a séries temporais confiáveis é essencial para a simulação de portfólios, cálculo de métricas financeiras e análise de risco-retorno.
- **Numpy e Pandas:** Bibliotecas fundamentais para manipulação e análise de dados numéricos em Python. O Numpy é responsável por operações vetoriais e matrizes, enquanto o Pandas oferece estruturas eficientes para tratamento, filtragem, agregação e análise de conjuntos de dados tabulares.

3 Descrição da Aplicação e Fluxo de Operação

A aplicação desenvolvida busca proporcionar uma experiência personalizada e interativa ao usuário, utilizando inteligência artificial para interpretar perfis, recomendar portfólios e auxiliar na tomada de decisão financeira. O sistema foi projetado para ser acessível a investidores de diferentes níveis de conhecimento, integrando recursos de linguagem natural, cálculos automáticos e visualização gráfica em um único ambiente. O fluxo de operação do usuário é estruturado conforme as etapas a seguir.

3.1 Fluxo de Operação do Usuário

1. **Entrada do Perfil do Usuário:** O usuário inicia o processo descrevendo seu perfil de investimento em linguagem natural, detalhando preferências, objetivos, tolerância ao risco e horizonte de investimento. Essa entrada textual é encaminhada ao Large Language Model (LLM), responsável por interpretar e extrair informações relevantes.
2. **Geração do Portfólio:** Com base na análise do perfil realizada pela LLM, a aplicação sugere automaticamente uma carteira de investimentos personalizada, adequada às necessidades e características do usuário.
3. **Cálculo de Métricas e Visualizações:** O portfólio sugerido é então avaliado por meio do cálculo das principais métricas financeiras — como volatilidade, Value at Risk (VaR), índice de Sharpe, drawdown, entre outras — além da geração dos gráficos correspondentes, como Retorno Simulado vs. Realizado, Matriz de Correlação e Volatilidade vs. Retorno.
4. **Apresentação dos Resultados:** Todas as informações e visualizações são exibidas na interface da aplicação de forma clara, interativa e acessível, facilitando a compreensão dos dados e permitindo uma análise detalhada das recomendações.
5. **Ajustes Iterativos:** Caso deseje, o usuário pode solicitar alterações na composição do portfólio ou ajustar suas preferências. O sistema processa as novas solicitações e atualiza automaticamente as métricas e visualizações, permitindo um ciclo iterativo de personalização até que a solução apresentada esteja totalmente alinhada com os objetivos do usuário.




Fig. 1. Fluxo operacional da aplicação, desde a entrada do perfil até a exibição dos dados ao usuário.

Esse fluxo operacional dinâmico torna a aplicação uma ferramenta poderosa para democratizar o acesso à informação financeira, promovendo autonomia, compreensão e segurança na tomada de decisão sobre investimentos.

3.2 Simulação de Monte Carlo para Retorno Esperado de Portfólio

Descrição do Algoritmo A simulação de Monte Carlo é uma técnica estatística amplamente utilizada para modelar a incerteza de sistemas complexos por meio da geração de cenários aleatórios. Em finanças, ela permite estimar o comportamento futuro de um portfólio ao simular milhares de possíveis trajetórias dos preços dos ativos, considerando suas características históricas, como média de retorno (CER — Constant Expected Return), volatilidade e correlação entre ativos.

No contexto desta aplicação, a simulação de Monte Carlo consiste nos seguintes passos:

1. Estimar o retorno esperado (CER), volatilidade e matriz de covariância dos ativos a partir dos dados históricos.
2. Para cada simulação, gerar sequências de retornos diários para cada ativo, utilizando a distribuição normal com média igual ao retorno esperado e desvio padrão igual à volatilidade.
3. Calcular o valor futuro do portfólio em cada simulação, agregando os resultados conforme as proporções de alocação dos ativos.
4. Repetir o processo milhares de vezes para obter uma distribuição empírica dos possíveis retornos do portfólio.

Essa abordagem permite visualizar a dispersão dos resultados possíveis, quantificar o risco de perdas extremas (VaR, drawdown) e estimar intervalos de confiança para o retorno futuro do portfólio.

Gráficos Gerados e Interpretação A aplicação oferece três principais visualizações a partir dos resultados da simulação de Monte Carlo e das análises complementares:

- **Retorno Simulado vs. Retorno Realizado:** Este gráfico apresenta, em um mesmo eixo temporal, o desempenho histórico do portfólio (realizado) até o presente e as trajetórias simuladas para o futuro, geradas via Monte Carlo. Assim, permite visualizar claramente a transição entre o que efetivamente ocorreu no passado e o leque de possíveis cenários futuros previstos pelo modelo. Esta visualização é fundamental para transmitir ao usuário a incerteza inerente às projeções e o intervalo de retornos potenciais a partir do momento atual, auxiliando na avaliação de riscos e expectativas para o portfólio.
- **Matriz de Correlação:** Apresentada geralmente como um mapa de calor, esta matriz revela como os retornos dos diferentes ativos estão relacionados entre si. Correlações altas sugerem que os ativos tendem a se mover juntos (aumentando o risco sistemático), enquanto correlações baixas ou negativas favorecem a diversificação e redução do risco agregado do portfólio.
- **Gráfico Risco x Retorno:** Este gráfico posiciona cada ativo (ou portfólio simulado) em um plano onde o eixo x representa a volatilidade (risco) e o eixo y, o retorno esperado. Permite identificar quais ativos oferecem melhor relação risco-retorno, ilustrando a fronteira eficiente. O investidor pode, assim, optar por carteiras mais estáveis ou mais arrojadas conforme seu perfil.

Dessa forma, a combinação de simulação de Monte Carlo com as visualizações gráficas permite ao usuário não apenas compreender as métricas agregadas, mas também obter uma intuição visual sobre as incertezas, correlações e o potencial de desempenho de cada carteira sugerida pela aplicação.

4 Implementação e Disponibilidade do Código

O código-fonte completo da aplicação, incluindo a implementação dos métodos de simulação, cálculo das métricas financeiras e integração com a interface gráfica, está disponível publicamente no repositório GitHub do projeto:

– <https://github.com/TheoCohenF/risk-simul-ufrj>

Abaixo, exemplificamos um trecho central da implementação do método de simulação de preços futuros com retorno esperado constante (Constant Expected Return, CER). Esse método utiliza os parâmetros estimados de média e desvio padrão dos log-retornos históricos dos ativos para gerar trajetórias possíveis de preços futuros via simulação de Monte Carlo:

```
1 def _get_future_prices_sample(self, num_days=21):
2     log_returns = self._rng.normal(
3         self._difflogs_mean,
4         self._difflogs_std,
5         num_days
6     )
7     future_prices = self._current_price * np.exp(np.cumsum(
8         log_returns))
9     last_date = self._historical_prices.index[-1]
10    interval = self._historical_prices.index.to_series().diff(
11        ).min()
12    future_dates = [
13        last_date + (i + 1)*interval for i in range(len(
14            future_prices))
15    ]
16    return pd.Series(future_prices, index=future_dates)
17
18 def run(self, num_simulations=3_000, num_days=21):
19     scenarios = []
20     for i in range(num_simulations):
21         scenarios.append(self._get_future_prices_sample(
22             num_days))
23     self._future_prices = pd.DataFrame(scenarios).mean(axis
24         =0)
25     return
```

Listing 1.1. Exemplo de simulação de preços futuros com CER

Este código simula `num_simulations` cenários para os preços futuros do ativo ao longo de `num_days`, assumindo um retorno logarítmico constante e normalmente distribuído, de acordo com a hipótese de CER. O resultado é a média dos

cenários gerados, que pode ser usada para projeções e construção dos gráficos de retorno simulado.

5 Exemplo Prático de Simulação e Resultados

Para ilustrar o funcionamento da aplicação desenvolvida, apresentamos nesta seção um exemplo prático de simulação de portfólio rodando em ambiente real. O processo abrange desde a descrição do perfil do usuário, a recomendação de portfólio, a geração das métricas de risco e a visualização dos principais gráficos. Todas as etapas foram registradas com capturas de tela, evidenciando a experiência interativa oferecida ao usuário.

5.1 Execução do Simulador

No cenário demonstrado, um usuário informa seu perfil de investimento utilizando linguagem natural, por exemplo: *“Prefiro investimentos moderados, com potencial de crescimento no longo prazo, mas sem grandes oscilações. Meu objetivo é preservar o capital e obter rentabilidade acima da inflação.”*

A aplicação processa a entrada, gera uma carteira sugerida e apresenta as métricas calculadas. Em seguida, os resultados são exibidos em gráficos interativos.

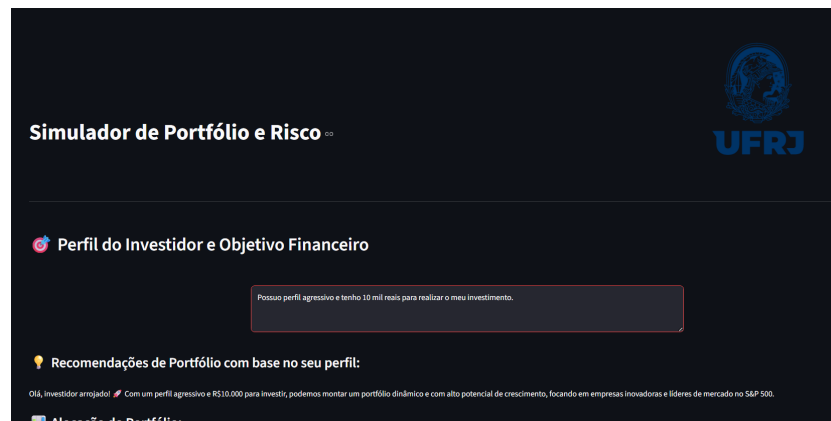


Fig. 2. Tela inicial do programa onde o usuário descreve seu perfil e o valor a ser investido.

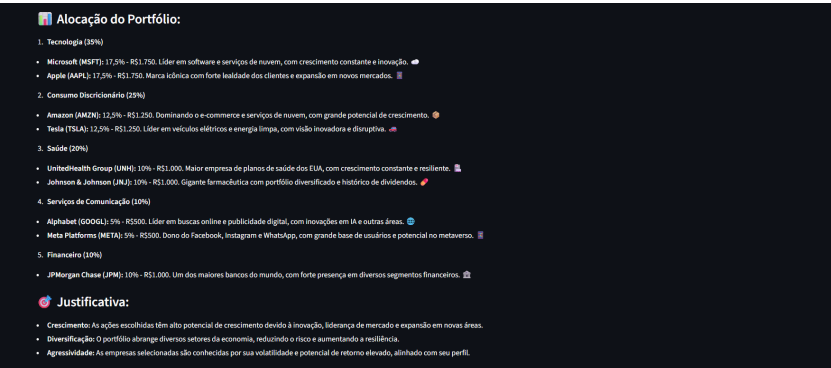


Fig. 3. Portfólio sugerido para o usuário e a justificativa.

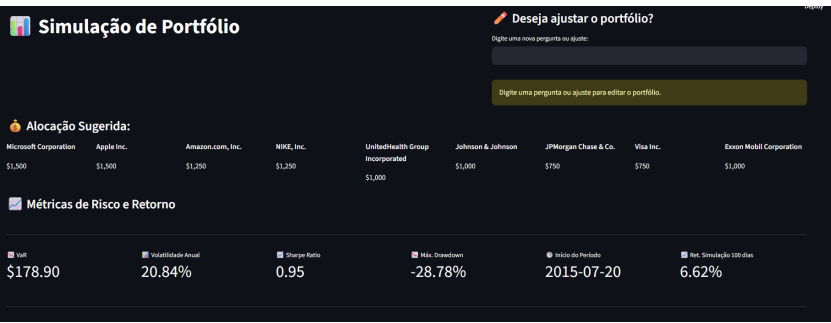


Fig. 4. Métricas calculadas para o portfólio recomendado.

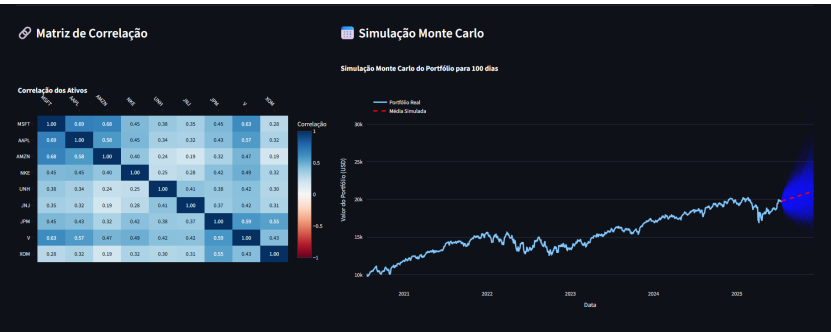


Fig. 5. Gráficos de correlação e simulação.




Fig. 6. Gráficos de volatilidade por risco e distribuição dos retornos simulados.

5.2 Demonstração em Vídeo

Para uma demonstração completa da interação com a aplicação, incluindo as funcionalidades dinâmicas e ajustes iterativos do portfólio, disponibilizamos um vídeo no YouTube:

<https://youtu.be/eF2gBoM-vMs>

Este vídeo apresenta o fluxo de uso, os resultados das simulações e exemplos de interpretação dos gráficos pelo usuário.

6 Conclusão

Este trabalho apresentou o desenvolvimento de um simulador inteligente de portfólios baseado em LLM e simulação de Monte Carlo. O sistema mostrou-se eficiente para interpretar perfis de investidores, sugerir carteiras personalizadas e comunicar métricas de risco e retorno de forma intuitiva. Apesar dos avanços, a aplicação ainda pode ser aprimorada com a inclusão de dados de mercados internacionais, integração com plataformas de investimento e experimentação com outros algoritmos de otimização.

References

1. BEHERA, Aman. *Portfolio Optimisation using Monte Carlo Simulation*. Medium, 2023. Disponível em: <https://medium.com/@beingamanforever/portfolio-optimisation-using-monte-carlo-simulation-25d88003782e>. Acesso em: 18 jul. 2025.
2. WIKIPEDIA. *RiskMetrics*. Disponível em: <https://en.wikipedia.org/wiki/RiskMetrics>. Acesso em: 18 jul. 2025.